

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Docente:
Prof. José Canelón, Ph.D.

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

CONTENIDO DEL CURSO

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Descripción del Curso

Contenido del Curso

- Unidad I: Fundamentos de Aprendizaje Automático y PyTorch
- Unidad II: Redes Neuronales: Shallow y Profundas
- Unidad III: Redes Neuronales Convolucionales (CNNs)
- Unidad IV: Computer Vision: Clasificación, Detección, Segmentación y OCR
- Unidad V: Aprendizaje Auto-Supervisado e IA Responsable
- Unidad VI: Modelos de Secuencias: RNN, LSTM, GRU y TCN
- Unidad VII: Deep Learning para Series de Tiempo
- Unidad VIII: Procesamiento de Señales: DSP Clásico y Deep Learning

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Descripción del Curso

Metodología

- 15 clases
- 6 horas por clase: 3 horas de teoría + 3 horas de práctica
- Formato presencial/virtual

Stack tecnológico

- Python 3.11+, PyTorch 2.x, torchvision, torchaudio
- Google Colab (gratuito) o entorno local con CUDA
- AWS SageMaker para prácticas cloud (Unidades seleccionadas)
- Weights & Biases para experiment tracking

Evaluación

- Trabajos Prácticos
- Examen Parcial

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Descripción del Curso

Evaluación y Criterios de Aprobación

Condiciones de aprobación

- Asistencia mínima exigida por la Universidad
- Aprobación de todas las actividades prácticas
- Aprobación del Examen Parcial

Examen Final

- Evaluación escrita, presencial e individual
- Abarca todos los temas del programa
- Aprobación: Mínimo 60/100 (corresponde a 4)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Descripción del Curso

Bibliografía Obligatoria

- Géron, A. — Hands-On ML with Scikit-Learn, Keras & TensorFlow, 3ª ed. — O'Reilly, 2022
- Howard, J. & Gugger, S. — Deep Learning for Coders with fastai and PyTorch — O'Reilly, 2020
- Raschka, S. et al. — Machine Learning with PyTorch and Scikit-Learn — Packt, 2022
- Chollet, F. — Deep Learning with Python, 2ª ed. — Manning, 2021

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Descripción del Curso

Bibliografía Adicional

- Goodfellow, I. et al. — Deep Learning — MIT Press, 2016 — deeplearningbook.org (gratis)
- Prince, S. — Understanding Deep Learning — MIT Press, 2023 — udlbook.github.io (gratis)
- MIT 6.S191 — Introduction to Deep Learning — introtodeeplearning.com
- Stanford CS231n — Deep Learning for Computer Vision — cs231n.stanford.edu

UNIDAD I

**FUNDAMENTOS DE
APRENDIZAJE AUTOMÁTICO Y
PYTORCH**

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Contenido

- Panorama de IA, ML y Deep Learning
- Tipos de aprendizaje
- Pipeline completo de un proyecto de DL
- Introducción a PyTorch
- Principales Plataformas de ML
- Visión por Computadora

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

¿Qué es la Inteligencia Artificial?

- Campo amplio de la informática que busca crear sistemas capaces de realizar tareas que normalmente requieren inteligencia humana

Definición operacional (McCarthy, 1956)

- La ciencia e ingeniería de crear máquinas inteligentes

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Inteligencia Artificial

Tipos de IA por capacidad

- IA Estrecha (ANI): especializada en una sola tarea (estado del arte actual)
- IA General (AGI): capacidades comparables a un humano en cualquier tarea (objetivo de largo plazo)
- IA Superinteligente (ASI): supera a los humanos en todas las dimensiones (especulativa)


Ramas principales de la IA

- Machine Learning, Visión Computacional, Procesamiento de Lenguaje Natural (NLP)
- Robótica, Sistemas Expertos, Planificación y Búsqueda

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Jerarquización IA/ML/DL



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Jerarquización IA/ML/DL

Inteligencia Artificial (IA)

- Cualquier técnica que permita a las máquinas imitar la inteligencia humana
- Incluye reglas explícitas, búsqueda, planning — no necesariamente datos

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Jerarquización IA/ML/DL

Machine Learning (ML) $\subset$ IA

- Subset de IA: programas que aprenden de los datos sin ser explícitamente programados
- El modelo infiere las reglas a partir de ejemplos — generaliza a casos nuevos

Deep Learning (DL) $\subset$ ML $\subset$ IA

- Subset de ML: redes neuronales artificiales con múltiples capas
- Aprende representaciones jerárquicas: píxeles $\rightarrow$ bordes $\rightarrow$ formas $\rightarrow$ objetos
- Escala excepcionalmente bien con datos y cómputo — base de los modelos modernos

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Historia del Deep Learning

- 1943 — McCulloch & Pitts: primer modelo matemático de neurona artificial
- 1958 — Rosenblatt: Perceptrón — primer algoritmo de aprendizaje
- 1986 — Rumelhart, Hinton & Williams: Backpropagation — entrenamiento de redes multicapa
- 1989 — LeCun: CNNs para reconocimiento de dígitos (MNIST)
- 1997 — Hochreiter & Schmidhuber: LSTM — redes recurrentes con memoria larga

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Historia del Deep Learning

- 2012 — AlexNet: CNN profunda gana ImageNet por un margen histórico (error: 16% vs 26%)
- 2014 — GANs (Goodfellow et al.), Dropout, Batch Normalization
- 2017 — Transformer: 'Attention Is All You Need' (Vaswani et al.)
- 2018-2024 — Era de los LLMs: BERT, GPT, ChatGPT, Claude, Gemini

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

¿Por qué Deep Learning Ahora?

- El DL no es nuevo, lleva décadas de desarrollo teórico
- Factores que hacen dominante al Deep Learning:

1. Datos

- Explosión de datos digitales: internet, redes sociales, IoT, sensores industriales
- Datasets masivos etiquetados: ImageNet (14M imágenes), Common Crawl (PB de texto)

2. Cómputo (Hardware)

- GPUs: paralelismo masivo para multiplicación de matrices — 1000x más rápido que CPU
- TPUs (Google), AI chips (Apple Silicon, NVIDIA H100/A100)
- Cloud computing: acceso democratizado a cómputo sin inversión de capital

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

¿Por qué Deep Learning Ahora?

- Factores que hacen dominante al Deep Learning:

3. Algoritmos y Software

- Funciones de activación (ReLU), regularización (Dropout, Batch Norm)
- Frameworks: PyTorch, TensorFlow — diferenciación automática, GPU nativo
- Transfer learning: reutilizar modelos pre-entrenados en miles de millones de ejemplos

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aplicaciones de Deep Learning

Visión por Computadora (CV-Computer Vision)

- Clasificación de imágenes, detección de objetos (YOLO), segmentación semántica
- Diagnóstico médico: radiografías, dermatología, patología
- Vehículos autónomos, inspección industrial

Procesamiento de Lenguaje Natural (NLP-Natural Language Processing)

- LLMs (ChatGPT, Claude, Gemini): generación de texto, QA, traducción
- Análisis de sentimiento, clasificación de documentos, NER

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aplicaciones de Deep Learning

Series de Tiempo y Señales

- Pronóstico de demanda eléctrica, precios de activos financieros
- Clasificación de arritmias (ECG), reconocimiento de fonemas (audio)
- Detección de anomalías en señales industriales (mantenimiento predictivo)

Generative AI

- Stable Diffusion, DALL-E, Sora — generación de imágenes y video

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Machine Learning Clásico

- Datos tabulares estructurados (filas y columnas)
- Datasets pequeños-medianos (< 100K filas)
- Interpretabilidad requerida (feature importance)
- Tiempo de entrenamiento limitado
- XGBoost, LightGBM, Random Forest, SVM

Regla práctica

- Empezar siempre con un modelo clásico como baseline

Deep Learning

- Imágenes, texto, audio, señales
- Datasets grandes (>100K ejemplos)
- Extracción automática de features
- GPU disponible para entrenamiento
- PyTorch, TensorFlow/Keras

Regla práctica

- DL supera a ML clásico cuando los datos son suficientes y el dominio lo justifica

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Tipos de Aprendizaje

Según la supervisión durante el entrenamiento

- Aprendizaje Supervisado: datos etiquetados → predecir target
- Aprendizaje No Supervisado: sin etiquetas → encontrar estructura
- Semi-Supervisado: pocos datos etiquetados + muchos sin etiqueta
- Self-Supervised: el modelo genera sus propias etiquetas (BERT, GPT, CLIP, MAE)
- Aprendizaje por Refuerzo: agente + entorno + recompensa → política óptima

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Tipos de Aprendizaje

Según cómo aprende el modelo

- Batch learning: entrenamiento offline con todos los datos a la vez
- Online (incremental) learning: aprende de mini-batches continuamente


Según el tipo de generalización

- Instance-based (k-NN): memoriza ejemplos y generaliza por similitud
- Model-based (regresión, redes neuronales): ajusta parámetros para generalizar

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Supervisión durante el Entrenamiento



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje Supervisado

- El conjunto de entrenamiento incluye etiquetas (labels/targets)
- El modelo aprende a predecir el target a partir de los features de entrada
- Durante el entrenamiento: el algoritmo ajusta parámetros para minimizar una función de pérdida (loss function)
 - MSE
 - Binary cross-entropy
 - Categorical cross-entropy

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje Supervisado

Dos grandes tareas

- Regresión: predicción de un valor continuo (precio, temperatura, demanda)
- Clasificación: predicción de una categoría (spam/no spam, clase 0/1/2)

Algunos algoritmos destacados

- Regresión lineal, Regresión logística, SVM, Árboles de decisión
- Random Forest, Gradient Boosting (XGBoost, LightGBM)
- Redes Neuronales Profundas (DL)


Aprendizaje Supervisado Regresión

- **Objetivo:** predecir un valor numérico continuo
- **Ejemplo:** satisfacción de vida en función del PBI per cápita
El modelo seleccionado es una función lineal:
$$\text{life_satisfaction} = \theta_0 + \theta_1 \times \text{GDP_per_capita}$$
- **Métricas comunes:**
 - MAE (Error Absoluto Medio)
 - RMSE (Raíz del Error Cuadrático Medio)
 - R^2 (coeficiente de determinación)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I



Aprendizaje Supervisado Regresión



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje Supervisado Regresión



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje Supervisado **Clasificación**

- Objetivo: predecir a qué clase pertenece una instancia
- El modelo aprende fronteras de decisión en el espacio de features

Tipos

- Binaria: spam / no-spam; fraude / legítimo; enfermo / sano
- Multiclase: dígitos 0-9, especie de flor, tipo de transacción
- Multilabel: un e-mail puede: ser urgente Y contener adjuntos Y ser spam
- Multioutput: predicción de múltiples valores categóricos simultáneos

Métricas comunes



- Accuracy, Precision, Recall, F1-Score, ROC-AUC, Confusion Matrix

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje Supervisado

Clasificación



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado

- Datos de entrenamiento NO están etiquetados (no hay target)
- El algoritmo intenta encontrar estructura y patrones en el espacio de entrada

Principales tareas

- Clustering: agrupar instancias similares
- Reducción de dimensionalidad: comprimir sin perder información
- Detección de anomalías: identificar instancias inusuales
- Aprendizaje de densidad: estimar la distribución de los datos
- Aprendizaje generativo: generar nuevas instancias similares a los datos de entrenamiento




Usos comunes

- Segmentación de clientes, compresión de datos, pre-entrenamiento no supervisado

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado Clustering

- Agrupa instancias similares sin conocer las clases de antemano

Algoritmos principales

- K-Means: partición en k clusters minimizando la varianza intra-cluster
- DBSCAN: clustering basado en densidad, detecta formas arbitrarias
- Gaussian Mixture Models (GMM): asignación probabilística a clusters
- Hierarchical clustering: dendrograma de agrupamientos anidados




Aplicaciones

- Segmentación de clientes por comportamiento de compra
- Detección de grupos de anomalías en series de tiempo industriales
- Agrupamiento de documentos por temática (topic modeling)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado Clustering



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado

Reducción de Dimensionalidad

- Simplificar los datos sin perder demasiada información relevante
- Combinar features correlacionados en uno solo (feature extraction)

Algoritmos

- PCA (Principal Component Analysis): proyección lineal de mínima varianza perdida
- t-SNE: visualización no lineal, preserva estructura local
- UMAP: más rápido que t-SNE, preserva estructura global y local
- Autoencoders: codificación no lineal con redes neuronales


Beneficios

- Reduce el tiempo de entrenamiento y el overfitting (curse of dimensionality)
- Facilita la visualización de datos de alta dimensión


INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado Reducción de Dimensionalidad



- automobile
- truck
- frog
- × ship
- airplane
- ◇ horse
- △ bird
- ▽ dog
- ▷ deer



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado

Detección de Anomalías

- Detectar instancias atípicas (outliers) que difieren significativamente del patrón normal

Aplicaciones

- Detección de fraude financiero en tiempo real
- Monitoreo de equipos industriales (vibración, temperatura, presión)
- Calidad de manufactura: rechazo de piezas defectuosas

Algoritmos comunes


- Isolation Forest, Local Outlier Factor (LOF), One-Class SVM, Autoencoders

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje No Supervisado

Detección de Anomalías



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje por Refuerzo (RL)

- Un agente observa el entorno, toma acciones y recibe recompensas o penalidades
- El objetivo es aprender la política óptima (policy) que maximiza la recompensa acumulada


Componentes

- Agente: el sistema que aprende y toma decisiones
- Entorno: el contexto con el que interactúa el agente
- Estado: representación actual del entorno
- Acción: lo que el agente puede hacer en cada estado
- Recompensa: señal de retroalimentación del entorno
- Política: la estrategia que el agente sigue


INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje por Refuerzo (RL)



- 1 Observe
- 2 Select action using policy



- 3 Action!
- 4 Get reward or penalty



- 5 Update policy (learning step)
- 6 Iterate until an optimal policy is found

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Aprendizaje por Refuerzo (RL)

Algoritmos y Aplicaciones

- Q-Learning, Deep Q-Networks (DQN), Policy Gradient (REINFORCE)
- Proximal Policy Optimization (PPO), Actor-Critic (A3C, SAC, TD3)

Aplicaciones destacadas

- AlphaGo / AlphaZero: supera a campeones mundiales de Go y Ajedrez (DeepMind, 2016-2017)
- OpenAI Five: equipo de bots que derrota a profesionales de Dota 2 (2019)
- Robots industriales: aprender tareas de manipulación complejas
- Control de procesos: optimización de PID en tiempo real
- Optimización de data centers: Google redujo consumo de energía 40% (DeepMind, 2016)
- Sistemas de recomendación adaptativos


INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Métodos Híbridos y Avanzados

Semi-Supervised Learning

- Combina datos etiquetados (pocos) con no etiquetados (muchos)
- Muy útil cuando etiquetar es costoso o tardado (ej: radiografías médicas)



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Métodos Híbridos y Avanzados

Self-Supervised Learning

- El modelo genera sus propias etiquetas desde los datos no etiquetados
- Base de modelos modernos: BERT, GPT, MAE, CLIP

Transfer Learning

- Reutilizar un modelo pre-entrenado en una tarea como punto de partida para otra

Ensemble Methods

- Combinar múltiples modelos para mejorar performance
- Bagging (Random Forest), Boosting (XGBoost, LightGBM), Stacking

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Capacidad de aprender en línea **Batch Learning vs. Online Learning**

Batch Learning (Offline)

- El sistema se entrena con todos los datos disponibles de una vez
- Luego se despliega sin seguir aprendiendo (estático)
- Para re-entrenarlo: proceso completo con nuevos datos + redeploy
- Adecuado para la mayoría de aplicaciones empresariales
- Requiere más tiempo
- Requiere más recursos
- Se lanza a producción estáticamente (Aplica lo aprendido)
- Requiere reentrenamiento (Model drift, Data drift)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Capacidad de aprender en línea **Batch Learning vs. Online Learning**


Online Learning (Incremental)

- Entrenamiento incremental: Rápido y económico
- El sistema aprende de mini-batches de datos continuamente
- Se adapta a cambios en los datos en tiempo real (data streams)
- Parámetro clave: learning rate (adaptación rápida vs. ruido)
 - Más alta, mayor sensibilidad
 - Más baja, mayor inercia
- Aplicaciones: trading algorítmico, detección de fraude en streaming

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Capacidad de aprender en línea Batch Learning vs. Online Learning Online Learning (Incremental)



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Instance-based Learning

- Memoriza los ejemplos de entrenamiento
- Generaliza usando una medida de similitud
- Ejemplo: k-NN (k vecinos más cercanos)
- No construye un modelo explícito
- Lento en predicción, rápido en entrenamiento

Model-based Learning

- Construye un modelo a partir de los datos de entrenamiento
- Usa el modelo para hacer predicciones nuevas
- Ejemplos: regresión lineal, árboles de decisión, redes neuronales
- Rápido en predicción (solo evaluar la función)
- Los parámetros del modelo son los 'aprendidos'

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

En el contexto de DL...

Aprendizaje Supervisado

- La mayoría de las tareas en CV, NLP y series de tiempo son supervisadas
- Requieren datasets etiquetados — costoso y lento de construir

Transfer Learning

- Reutilizar un modelo pre-entrenado en una tarea como punto de partida para otra
- Fine-tuning de modelos foundation (GPT, BERT, ResNet, YOLO)
- Fundamental en aplicaciones de CV y NLP

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

En el contexto de DL...

Self-Supervised — DL moderno

- El modelo genera sus propias etiquetas a partir de los datos no etiquetados
- BERT: predice palabras enmascaradas en texto (Masked Language Modeling)
- GPT: predice el siguiente token dado el contexto anterior
- MAE: reconstruye regiones enmascaradas de imágenes
- CLIP: alinea representaciones de imagen y texto por contraste

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Pipeline Completo de un Proyecto de DL

- Un proyecto de DL sigue un ciclo iterativo con 6 fases principales
 1. Definición del problema y métricas de negocio
 2. Recolección, exploración y preparación de datos (EDA)
 3. Ingeniería de features y augmentation
 4. Diseño y selección de arquitectura del modelo
 5. Entrenamiento, validación y evaluación
 6. Despliegue, monitoreo y mantenimiento
- El ciclo es iterativo — retornar a pasos anteriores es normal y esperado

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Paso 1 — Definición del Problema

Preguntas clave a responder

- ¿Cuál es el objetivo de negocio? ¿Cómo se mide el éxito?
- ¿Es un problema supervisado / no supervisado / RL?
- ¿Regresión o clasificación? ¿Cuántas clases?
- ¿Qué datos existen? ¿Son suficientes? ¿Están etiquetados?
- ¿Qué latencia se requiere en producción? (batch vs tiempo real)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Paso 1 — Definición del Problema

Métricas: negocio vs modelo

- Métrica de negocio: ingresos, costo evitado, NPS, satisfacción del cliente
- Métrica de modelo: accuracy, F1, MAE, RMSE, AUC-ROC, mAP
- Deben estar alineadas — optimizar el modelo $\neq$ optimizar el negocio necesariamente

Baseline

- Puede ser útil definir un baseline simple antes de cualquier DL: regla heurística, modelo lineal, media

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Pasos 2-3 — Datos y Preprocesamiento

Recolección y EDA (Exploratory Data Analysis)

- Fuentes: bases de datos, APIs, scrapers, sensores, datos sintéticos
- EDA: distribuciones, correlaciones, valores faltantes, outliers, duplicados

Preparación

- Limpieza: imputación, corrección de errores, eliminación de duplicados
- Transformaciones: normalización, estandarización, encoding de categorías
- Split train / validation / test — evitar data leakage

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Pasos 2-3 — Datos y Preprocesamiento

Ingeniería de Features y Data Augmentation

- Features manuales: dominio experto, lags, rolling statistics (series de tiempo)
- Data augmentation para imágenes: rotación, flip, recorte, color jitter
- Augmentation para audio: time stretch, pitch shift, additive noise

Herramientas

- pandas, scikit-learn, Albumentations, torchaudio.transforms

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Pasos 4-6 — Modelo, Entrenamiento y Deployment

Diseño del Modelo

- Selección de arquitectura: MLP, CNN, RNN/LSTM, Transformer, híbrido
- Inicialización de pesos, función de activación, función de pérdida

Entrenamiento

- Loop: forward pass → cálculo de pérdida → backward → update de parámetros
- Optimizador: SGD, Adam, AdamW — learning rate scheduling
- Regularización: dropout, weight decay, early stopping

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Pasos 4-6 — Modelo, Entrenamiento y Deployment

Evaluación

- Métricas sobre el validation set — ajuste de hiperparámetros
- Test set: evaluación final — solo se usa UNA VEZ
- Análisis de errores: ¿dónde falla el modelo?

Deployment y Monitoreo

- Despliegue como API REST / batch job / embedded model
- Monitoreo: data drift, model degradation, alertas de re-entrenamiento

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I


Train / Validation / Test Split

- Para evaluar correctamente un modelo, se separan los datos en tres conjuntos
 - Training Set (~70-80%): Se usa para ajustar los parámetros del modelo
 - Validation Set (~10-15%):
 - ✓ Se usa para ajustar hiperparámetros y selección de modelo
 - ✓ NO se usa en el entrenamiento
 - Test Set (~10-20%)
 - ✓ Evaluación final del modelo seleccionado — se usa UNA SOLA VEZ
 - ✓ Estima la performance de generalización (producción)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Train / Validation / Test Split



INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Fundamentos Matemáticos

- Álgebra Lineal
 - Operaciones con matrices y vectores
 - Normas
- Cálculo Vectorial
 - Derivadas
 - Reglas de cadena
 - Derivadas Parciales, Gradiente
- Estadística

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

PyTorch

- Framework de Deep Learning de Meta AI — el estándar en investigación académica

Características clave

- Las operaciones se ejecutan de inmediato, no se compilan (Eager execution)
- Define-by-run: el grafo computacional se construye dinámicamente (Python-native)
- Debugging sencillo: se puede usar `print()`, breakpoints, inspeccionar tensores en cualquier momento
- `torch.autograd`: diferenciación automática — calcula gradientes automáticamente
- Integración nativa con GPU (CUDA) y MPS (Apple Silicon)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

PyTorch

Ecosistema

- torchvision: datasets e modelos pre-entrenados para Computer Vision
- torchaudio: procesamiento de audio y señales
- Hugging Face Transformers: LLMs y modelos pre-entrenados
- PyTorch Lightning: abstracción para entrenamiento reproducible

Instalación

- `pip install torch torchvision torchaudio --index-url https://download.pytorch.org/whl/cu121`
- Verificar: `import torch; print(torch.__version__); print(torch.cuda.is_available())`

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

¿Qué es un Tensor?

- Estructura de datos multi-dimensional — la unidad fundamental de PyTorch

Propiedades de un tensor

- shape: dimensiones — `t.shape` o `t.size()`
- dtype: tipo de dato — `float32`, `float64`, `int64`, `bool`
- device: dónde vive — `cpu` o `cuda:0`
- requires_grad: si PyTorch rastrea gradientes sobre este tensor

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

CPU

- 4–64 núcleos potentes y de propósito general
- Latencia baja — ideal para tareas secuenciales
- Caché de memoria rápida y grande (L1/L2/L3)
- Bueno para: lógica de control, preprocesamiento, modelos pequeños
- Límite: paralelismo limitado para operaciones matriciales masivas

GPU

- 1000s de núcleos pequeños y especializados (CUDA cores)
- Throughput altísimo para operaciones paralelas (matmul, conv)
- Tensor Cores (NVIDIA A100, H100): optimizados para FP16/BF16
- VRAM: 8 GB (T4), 24 GB (A10G), 40-80 GB (A100)
- Speedup típico sobre DL: 10x–100x vs CPU

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Principales Plataformas de ML

- El ecosistema de plataformas ML cubre el ciclo de vida completo del modelo en producción

Plataformas

- Kubernetes + Kubeflow: orquestación de containers y pipelines ML en cualquier nube
- AWS SageMaker: suite completa de ML de Amazon Web Services
- GCP Vertex AI: plataforma ML unificada de Google Cloud
- Azure Machine Learning: plataforma ML de Microsoft Azure
- Databricks: lakehouse con ML integrado, basada en Apache Spark + MLflow
- Weights & Biases (W&B): experiment tracking y visualización
- H2O.AI: AutoML y explainability para enterprise

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

MLOps y las Plataformas

- MLOps es la disciplina que conecta las plataformas con el ciclo de vida del modelo

Niveles de madurez MLOps (Google, 2020)

- Nivel 0 — Manual: notebook experiments, modelo en producción manual sin pipeline
- Nivel 1 — Pipeline ML: pipelines automatizados, CT (Continuous Training)
- Nivel 2 — Pipeline CI/CD: automatización completa de pruebas y despliegue

Herramientas por nivel

- Nivel 0: Jupyter + scikit-learn + exportación manual
- Nivel 1: MLflow + Airflow/Kubeflow + Feature Store
- Nivel 2: AWS SageMaker Pipelines / GCP Vertex AI / Azure ML Pipelines + CI/CD

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Plataformas Cloud (managed)

- AWS SageMaker: ecosistema AWS, líder de mercado
- GCP Vertex AI: mejor integración con Colab y BigQuery
- Azure ML: entornos corporativos Microsoft, regulated industries

Ventajas managed

- Sin gestión de infraestructura
- Escalado automático
- SLAs garantizados

Plataformas Open / Híbridas

- Kubernetes + Kubeflow: control total, cloud-agnostic
- Databricks: escala masiva con Spark, multi-cloud

Herramientas de MLOps

- W&B: experiment tracking, any platform
- H2O.AI: AutoML enterprise con explainability
- MLflow: estándar open-source de tracking + registry

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

AWS SageMaker

- Suite completa de ML de Amazon Web Services — líder del mercado cloud

Ventajas:

- Integración con el ecosistema AWS
 - S3 (datos), ECR (containers), CloudWatch (monitoreo), IAM (seguridad)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

AWS SageMaker

Capacidades principales

- SageMaker Studio: IDE de ML completo en el browser (notebooks, experimentos, modelos)
- Training Jobs: entrenamiento distribuido en instancias gestionadas (GPU/CPU)
- Pipelines: automatización del ciclo completo (datos → entrenamiento → deploy)
- Model Registry: versionado y aprobación de modelos para producción
- SageMaker Endpoints: despliegue de modelos como APIs REST escalables
- Feature Store: almacenamiento y servicio de features online/offline
- Autopilot: AutoML integrado (datos → modelo → explicabilidad)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

GCP Vertex AI

- Plataforma ML unificada de Google Cloud — integra todas las herramientas ML de GCP

Ventajas

- Integración nativa con BigQuery, Cloud Storage (GCS), y Colab
- Acceso a TPUs de Google para training de LLMs y DL

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

GCP Vertex AI

Componentes clave

- Vertex AI Workbench: notebooks gestionados (Colab Enterprise incluido)
- Training: entrenamiento distribuido con contenedores customizados
- Vertex AI Pipelines: basado en Kubeflow Pipelines, reproducible
- Model Registry: gestión del ciclo de vida de modelos
- Vertex AI Feature Store: servicio de features en tiempo real y batch
- AutoML: visión, tabular, texto, video — sin código
- Vertex AI Model Garden: acceso a modelos Foundation (Gemini, PaLM)

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Azure Machine Learning

- Plataforma de ML de Microsoft — fuerte integración con el ecosistema corporativo de Microsoft

Ventajas en entornos corporativos

- Integración nativa con Microsoft 365, Azure Active Directory, Power BI
- Azure DevOps para MLOps CI/CD
- Azure OpenAI Service: acceso a GPT-4 y modelos de OpenAI vía Azure
- Governance y compliance: GDPR, HIPAA, SOC 2 — fuerte en sectores regulados

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Azure Machine Learning

Componentes principales

- Azure ML Studio: espacio de trabajo visual + notebook + experimentos
- Compute Clusters: clusters de entrenamiento gestionados (CPU/GPU)
- Azure ML Pipelines: orquestación de pasos de ML
- Model Registry: versionado y despliegue de modelos
- Automated ML: AutoML con interpretabilidad integrada

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Kubernetes + Kubeflow

Kubernetes

- Orquestador de contenedores de código abierto (Google, 2014)
- Gestiona el despliegue, escalado y operación de aplicaciones en contenedores
- Base de la infraestructura cloud-native: AWS EKS, GCP GKE, Azure AKS

Kubeflow

- Extensión de Kubernetes: para ML pipelines y experimentos (Google, 2018)
- Kubeflow Pipelines: DAGs de componentes ML reproducibles
- Katib: hyperparameter tuning a escala (AutoML sobre K8s)
- KFServing (KServe): despliegue de modelos como endpoints REST/gRPC

Ventajas

- Cloud-agnostic: funciona en AWS, GCP, Azure, on-premise
- Control total sobre la infraestructura — adecuado para equipos grandes

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Databricks

- Plataforma de Data + AI unificada — origen en Apache Spark (UC Berkeley)
- Concepto Lakehouse: combina las ventajas de Data Lake y Data Warehouse

Ventajas

- Escala masiva: Spark distribuido para datasets de TB/PB
- Disponible en AWS, Azure y GCP — multi-cloud nativo
- Fuerte en empresas con datos estructurados y pipelines analíticos complejos

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Databricks

Capacidades ML

- Databricks Notebooks: colaborativos, multi-lenguaje (Python, SQL, Scala, R)
- MLflow integrado: experiment tracking, model registry, model serving
- AutoML: genera código de entrenamiento y baseline automáticamente
- Feature Store: centralización y reutilización de features
- Delta Lake: formato de tabla ACID para datos estructurados y semi-estructurados

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Weights & Biases (W&B)

- Plataforma de MLOps especializada en experiment tracking, visualización y colaboración

Funcionalidades principales

- `wandb.log()`: logging de métricas en tiempo real durante el entrenamiento
- Dashboard interactivo: visualización de curvas de pérdida, métricas, hiperparámetros
- Artifacts: versionado de datasets, modelos y evaluaciones
- Sweeps: hyperparameter tuning distribuido (Bayesian, grid, random search)
- Reports: documentación y sharing de experimentos en formato colaborativo

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Weights & Biases (W&B)

Integración

- Compatible con PyTorch, TensorFlow, Keras, scikit-learn, XGBoost, LightGBM
- Muy popular en investigación académica y equipos de DL en producción
- En este curso: uso desde Unidad II para tracking de experimentos

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

H2O.AI

- Plataforma open-source de ML y AutoML con foco en enterprise y explainability

H2O-3 (core platform)

- Framework ML distribuido en memoria — escala a datasets de TB
- Algoritmos: GBM, Random Forest, Deep Learning, GLM, Stacked Ensembles
- API en Python, R, Scala, Java

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

H2O.AI

H2O AutoML

- Automatiza el entrenamiento y tuning de múltiples modelos
- Produce un leaderboard con los mejores modelos ordenados por métrica
- Incluye un Stacked Ensemble final que combina los mejores modelos

Driverless AI (H2O.AI Enterprise)

- AutoML de producción con explicabilidad automática (LIME, SHAP)
- Generación automática de pipelines de datos y features
- Usado en banca, seguros, healthcare y telecomunicaciones

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Selección de Plataforma — Criterios

Criterios técnicos

- Escala del problema: volumen de datos, frecuencia de re-entrenamiento
- Tipo de modelos: tabular ML, DL, LLMs, visión
- Latencia requerida en producción: tiempo real vs. batch

Criterios económicos (FinOps)

- Costo de cómputo, almacenamiento y networking
- Licenciamiento: open-source vs. enterprise
- ROI: velocidad de entrega de modelos a producción

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Selección de Plataforma — Criterios

Criterios organizacionales

- Infraestructura existente: ¿ya están en AWS, Azure o GCP?
- Capacidad del equipo: ¿tienen DevOps/MLOps o prefieren managed?
- Regulación: GDPR, HIPAA, datos en la nube vs. on-premise

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Cloud (AWS / GCP / Azure)

- Escalado elástico: pagar solo lo que se usa
- Acceso a GPUs/TPUs sin inversión de capital
- Servicios managed: Feature Store, AutoML, pipelines
- Actualizaciones automáticas de plataforma
- Riesgo: vendor lock-in, costo variable impredecible
- Restricción: datos sensibles / regulación pueden prohibir nube pública

On-Premise / Privado

- Control total sobre datos e infraestructura
- Costo fijo predecible a largo plazo
- Cumplimiento regulatorio más sencillo
- Riesgo: inversión de capital alta
- Requiere equipo de infraestructura dedicado
- Actualizaciones manuales — retrasos tecnológicos

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Visión por Computadora

- Todos los días interactuamos con modelos de aprendizaje profundo para visión por computadora (deep vision models) en
 - Google Photos, Google image search. YouTube, filtros de video en aplicaciones de cámaras, Software de OCR, entre otros
- Estos modelos también están presentes en esfuerzos esenciales de investigación/desarrollo en áreas como
 - Autos de conducción autónoma
 - Robótica
 - Diagnóstico médico asistido por IA
 - Sistemas autónomos de cobro en comercios minoristas
 - Agricultura autónoma

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Visión por Computadora

- El área de visión por computadora representó el primer gran éxito de los modelos de aprendizaje profundo, entre 2011 y 2015
- El modelo de **Red Neuronal Convolutiva (CNN)** fue el responsable de dicho éxito, mostrando resultados extraordinariamente buenos en tareas de clasificación de imágenes
- Para ese momento, los investigadores en visión por computadora habían invertido varios años en métodos diferentes a las redes neuronales, así que no estaban listos para cambiar de paradigma

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Visión por Computadora

- Los **Transformers** comenzaron a utilizarse en visión por computadora en el año 2020, con la publicación del artículo: "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", por Alexey Dosovitskiy et al., Google Research (ICLR 2021)
- Este trabajo introdujo el modelo **ViT (Vision Transformer)**, que adaptó directamente la arquitectura de Transformers usada en procesamiento de lenguaje natural (como en BERT o GPT) al dominio de las imágenes

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Visión por Computadora

- Grounding se refiere a alinear una expresión textual (como “el hombre con camisa azul”) con su referente visual (la región de la imagen donde aparece ese hombre)
- Permite a un modelo "entender dónde están las cosas de las que se está hablando".
- Es una conexión semántica entre lo visual y lo lingüístico, indispensable para modelos que interactúan con humanos o interpretan escenas complejas
- Es clave para tareas como:
 - Visión y lenguaje natural
 - Robots guiados por instrucciones
 - Navegación visual

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Visión por Computadora

Tipos de Grounding	¿A qué se refiere?
Grounding de objetos	Localiza en la imagen el objeto referido por una frase
Grounded captioning	Genera descripciones que están vinculadas a regiones específicas
Grounding textual	Determina qué partes de la imagen soportan o ilustran afirmaciones textuales
Grounded QA	Contesta preguntas basadas en evidencia visual localizada

Tareas de Visión por Computadora

Clasificación de imágenes (Image Classification)

- Consiste en determinar a qué clase pertenece una imagen completa
- Ejemplo de aplicación: Clasificar imágenes de diferentes animales
- Modelos típicos:
 - CNNs: ResNet, EfficientNet, VGG
 - Transformers: ViT, DeiT, BEiT
 - Híbridos: ConvNeXt, Swin Transformer

Tareas de Visión por Computadora


Detección de objetos (Object Detection)

- Consiste en identificar y localizar múltiples objetos en una imagen, devolviendo cajas delimitadoras y etiquetas
- Ejemplo de aplicación: Detectar todos los peatones y vehículos en una imagen urbana
- Modelos típicos:
 - CNNs: YOLOv5, Faster R-CNN, SSD
 - Transformers: DETR, DINO, YOLOS
 - Híbridos: RetinaNet-Swin, Sparse R-CNN + ViT

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Tareas de Visión por Computadora Detección de objetos (Object Detection)



Tareas de Visión por Computadora

Segmentación semántica (Semantic Segmentation)



- Consiste en asignar una etiqueta a cada píxel de la imagen, diferenciando regiones como “carretera”, “árbol”, “persona”...
- Ejemplo de aplicación: Mapeo preciso del entorno para vehículos autónomos.
- Modelos típicos:
 - CNNs: DeepLabV3+, FCN, U-Net
 - Transformers: SegFormer, Mask2Former
 - Híbridos: PANet + ViT, HRNet + attention

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Tareas de Visión por Computadora

Segmentación semántica (Semantic Segmentation)



Tareas de Visión por Computadora

Segmentación de instancias (Instance Segmentation)

- Es similar a la segmentación semántica, pero distinguiendo instancias individuales de la misma clase (por ejemplo, dos personas separadas)
- Ejemplo de aplicación: detectar y segmentar individualmente a cada peatón en una multitud
- Modelos típicos:
 - CNNs: Mask R-CNN
 - Transformers: Mask2Former
 - Híbridos: YOLACT + Transformer, SOLOv2 + Swin


INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción


Tareas de Visión por Computadora Segmentación de instancias (Instance Segmentation)



Input Image



Semantic Segmentation



Instance Segmentation

Tareas de Visión por Computadora

Reconocimiento facial (Face Recognition/Verification)


- Consiste en identificar o verificar la identidad de personas a partir de sus rostros.
- Ejemplo de aplicación: Desbloqueo facial en dispositivos móviles.
- Modelos típicos:
 - CNNs: VGGFace, OpenFace, DeepFace, FaceNet, ArcFace, Dlib + CNN
 - Transformers: ArcFace + ViT, InsightFace-ViT
 - Híbridos: MobileFace + attention

Tareas de Visión por Computadora

Estimación de pose (Pose Estimation)

- Consiste en determinar la posición y orientación del cuerpo humano (esqueleto 2D o 3D).
- Ejemplo de aplicación: Seguimiento de movimiento en videojuegos o fisioterapia.
- Modelos típicos:
 - CNNs: OpenPose, HourglassNet, HRNet
 - Transformers: PoseFormer, ViTPose
 - Híbridos: HRNet + Transformer

Tareas de Visión por Computadora Estimación de pose (Pose Estimation)




Tareas de Visión por Computadora **Reconocimiento de texto en imágenes** **(OCR / Scene Text Recognition)**

- Consiste en detectar y transcribir texto contenido en imágenes naturales o escaneadas.
- Ejemplo de aplicación: Leer matrículas, carteles o documentos escaneados.
- Modelos típicos:
 - CNNs: CRNN, Tesseract + CNN
 - Transformers: Transformers OCR, Donut
 - Híbridos: LayoutLMv3, OCRformer

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Tareas de Visión por Computadora Reconocimiento de texto en imágenes (OCR / Scene Text Recognition)



Detected attributes JSON

```
Nutrition Facts Amount Per Serving
Serving size: 1 bar (40g)
Serving Per Package: 4
Total Fat 13g
Saturated Fat 1.5g
Amount Per Serving
Trans Fat 0g
Calories 190
Calories from Fat 110
Cholesterol 0mg
Sodium 20mg
Daily Values are based on
Vitamin A 50%
calorie diet.
```

Tareas de Visión por Computadora **Visión multimodal y captioning**

- Consiste en generar descripciones de imágenes o interpretar imágenes y texto de forma conjunta.
- Ejemplo de aplicación: generar "Una mujer está andando en bicicleta junto a un perro".
- Modelos típicos:
 - CNNs: Show & Tell, CNN-RNN
 - Transformers: BLIP, GIT, Flamingo
 - Híbridos: CLIP, BLIP-2, Flamingo + ViT, ViT + LLM

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Tareas de Visión por Computadora

Visión multimodal y captioning

Visual Question Answering



QA: (How many portions is this pizza divided into? , 6)

Image-Text Retrieval



1. Five people meet in the restaurant.
2. Two men and three women are clinking glasses.
3. The man in red plaid shirt is clinking glasses and laughing with four people.

Image Captioning



A man in orange is skiing.

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Introducción

Tarea	Datasets
Clasificación de imágenes	ImageNet, CIFAR-10, MNIST
Detección de objetos	COCO, PASCAL VOC, Open Images
Segmentación semántica	Cityscapes, ADE20K, CamVid
Segmentación de instancias	COCO, Mapillary Vistas
Reconocimiento facial	LFW, VGGFace2, MS-Celeb-1M
Estimación de pose humana	MPII, COCO Keypoints, Human3.6M
Reconocimiento de texto (OCR)	IAM, ICDAR, SynthText, IIIT5K
Captioning de imágenes	MS-COCO Captions, Flickr8k/30k

INTELIGENCIA ARTIFICIAL Y APRENDIZAJE PROFUNDO I

Unidad I

Ejemplo: Datos Reales como Tensores

Chollet, Cap. 2 — Datasets reales y sus shapes

- Todo dataset en DL debe convertirse a tensores antes de entrar al modelo.

MNIST: imagenes de digitos escritos a mano

- 60,000 imagenes de entrenamiento, 10,000 de test — escala de grises
- Shape: (60000, 28, 28) — N imagenes de 28x28 pixeles
- Para MLP: aplanar a (60000, 784)
- Para CNN: agregar canal a (60000, 1, 28, 28) [formato NCHW de PyTorch]

Otros ejemplos de shapes reales

- Texto (IMDB reviews): (25000, 500) — 25K resenas, max 500 tokens
- Audio (1 seg, 16 kHz): (N, 16000) — N clips, 16000 muestras/segundo